

The background of the image is a solid dark blue. Overlaid on this background is a large, faint, circular pattern composed of numerous small red dots. These dots are arranged in a way that they form a ring around the central text, with some dots also scattered within the ring. The dots are more densely packed in some areas, creating a sense of depth and movement.

HUST

ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

ONE LOVE. ONE FUTURE.



ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

ĐÁNH GIÁ MODULAR REPRESENTATION & RECOGNIZER TRONG NHẬN DIỆN BẢNG CHỮ ASL

Computer Vision Capstone — Học kỳ 2025.2

Trần Quang Hưng - 20235502

Đỗ Đăng Vũ - 20235578

ONE LOVE, ONE FUTURE.
Lê Hoàng Tùng - 20235572

Trường Công nghệ Thông tin và Truyền thông - ĐHBK Hà Nội

Nội dung trình bày I

1. Đặt vấn đề
2. Mục tiêu & Đóng góp
3. Dữ liệu
4. Phương pháp
5. Phương pháp đánh giá
6. Kết quả
7. Kết luận
8. Phân công công việc



1. Bối cảnh & Động lực

Bối cảnh thực tế:

- ▶ Ngôn ngữ ký hiệu (ASL) là phương tiện giao tiếp chính của hàng triệu người khiếm thính.
- ▶ Hệ thống nhận diện ASL thời gian thực giúp giảm rào cản giao tiếp, không cần phần cứng chuyên dụng (chỉ cần webcam).

Thách thức kỹ thuật:

- ▶ Có rất nhiều lựa chọn kiến trúc: crop tay bằng detector hay dùng landmark? CNN hay Vision Transformer?
- ▶ **Câu hỏi cốt lõi:** Một representation "thông minh hơn" (crop tay, trích landmark, tăng cường ảnh) có thực sự cải thiện nhận diện, hay chỉ thêm độ phức tạp và thêm điểm có thể gây?
- ▶ Accuracy trên ảnh sạch có thể đánh lừa — cần đánh giá cả độ bền (robustness) dưới điều kiện thực tế.

2. Mục tiêu & Đóng góp

Câu hỏi nghiên cứu

Liệu các representation tốt hơn (hand-crop, landmark, enhancement) có thực sự cải thiện nhận diện A-Z, hay chỉ thêm độ phức tạp mà không thêm giá trị?

1. Framework module hóa

Tách riêng **Representation** và **Recognizer**, hoán đổi tự do — 13 pipeline khác nhau trên cùng 1 protocol.

2. Đánh giá đa chiều

Không chỉ accuracy sạch — còn macro-F1, robustness dưới 7–8 loại corruption, tỉ lệ phát hiện tay thất bại.

3. Phân tích trực quan sâu

Grad-CAM nội bộ CNN, UMAP/t-SNE không gian đặc trưng, qualitative grid so sánh từng bước pipeline.

3. Dataset Overview

Tập dữ liệu	Vai trò	Số lớp	Quy mô
ASL Alphabet (Kaggle) train	Train classifier / landmark MLP	26 (A–Z)	~78.000 ảnh
ASL Alphabet test_split	Đánh giá clean + robustness	26 (A–Z)	2.600 ảnh

Đặc điểm: ảnh studio, nền tương đối sạch, ánh sáng đều $\Rightarrow$ **dataset "dễ"** — nhiều pipeline đạt 99–100% accuracy trên ảnh sạch, accuracy sạch **không đủ** để phân biệt pipeline nào tốt hơn.

$\Rightarrow$ *Robustness benchmark (corruption) mới là phép thử thật sự phân biệt được các pipeline.*

4. Kiến trúc tổng quan — 2 Module

RGB image $\rightarrow$ **Representation Module** $\rightarrow$ **Recognizer Module** $\rightarrow$ A–Z

Module 1: Representation

Biến ảnh gốc thành thứ recognizer dùng được: ảnh crop, ảnh tăng cường, hoặc vector đặc trưng (landmark).

Module 2: Recognizer

Nhận output của representation, trả về 1 trong 26 nhãn A–Z, kèm top-k confidence.

13 pipeline = tổ hợp (Representation $\times$ Recognizer) hợp lệ, đánh giá trên cùng 1 protocol, cùng test set.

4.1 Module 1 — Representation (4 loại)

- ▶ **Raw image** — chỉ resize 224×224 , không xử lý gì thêm.
- ▶ **MediaPipe Crop** — HandLandmarker tìm 21 keypoint $\rightarrow$ tính bbox $\rightarrow$ crop + resize.
- ▶ **MediaPipe Landmarks** — giữ 21 keypoint dưới dạng vector 42 chiều (x,y mỗi điểm), chuẩn hóa theo cổ tay:

$$\text{point}_i \leftarrow \text{point}_i - \text{point}_{\text{wrist}}, \quad \text{feature}_i = \frac{\text{point}_i}{\max_j |\text{point}_j|}$$

Không còn texture/màu da — chỉ còn hình dáng tay.

- ▶ **Enhancement** — CLAHE / Gamma Correction / Sharpening / Denoising áp lên ảnh gốc rồi resize.

Lưu ý quan trọng: nếu MediaPipe không tìm được tay $\rightarrow$ representation trả None $\rightarrow$ recognizer tự động trả "Unknown" (luôn sai).

4.2 Module 2 — Recognizer (5 loại)

Recognizer	Loại mô hình	Input
ResNet18 (torchvision/resnet18_asl)	CNN, fine-tuned trên ASL	ảnh 224×224
SigLIP ViT (HuggingFace)	Vision Transformer, pretrained	ảnh 224×224
Landmark MLP	MLP nhỏ	vector 42-d
Landmark SVM	Support Vector Machine	vector 42-d
Landmark RF	Random Forest	vector 42-d

ViT/SigLIP được pretrain trên dữ liệu lớn — kỳ vọng lý thuyết: chính xác hơn và bền hơn với nhiễu so với ResNet18 train nhỏ.

5. Evaluation Metrics — cách tính chính xác

Vấn đề: accuracy "chuẩn" trong code chỉ tính trên ảnh *đã tìm được tay* — bỏ qua các ảnh "Unknown" khỏi cả tử và mẫu số!

Hai định nghĩa accuracy khác nhau

$$\text{clean_accuracy} = \frac{\# \text{đúng}}{\# \text{ảnh ĐÃ phát hiện tay}}$$

$$\text{accuracy_thực} = \frac{\# \text{đúng}}{\# \text{TỔNG ảnh (Unknown = ...}}}$$

- ▶ `hand_detection_failure_rate` = tỉ lệ ảnh representation trả None (chỉ áp dụng pipeline dùng MediaPipe).
- ▶ `worst_corruption_accuracy` = min accuracy qua 7–8 loại corruption (low-light, overexposure, motion-blur, gaussian-noise, rotation, scale-shift, partial-occlusion, crop-shift).

▶ Hệ quả: 1 pipeline có thể có `clean_accuracy` rất cao nhưng `accuracy_thực` thấp hơn nhiều — xem case study ở phần Kết quả.




6. Kết quả định lượng — 13 pipeline


Pipeline	Clean Acc	Macro-F1	Worst-case	Hand-fail	FPS
raw_siglip	1.0000	1.0000	0.8912	0.0%	6.3
enhancement_gamma_vit	1.0000	1.0000	0.8927	0.0%	22.9
enhancement_clahe_vit	0.9996	0.9996	0.8629	0.0%	9.3
raw_resnet18	0.9985	0.9985	0.9202	0.0%	222.3
enhancement_gamma_resnet18	0.9985	0.9985	0.9135	0.0%	21.8
enhancement_sharpen_resnet18	0.9965	0.9965	0.1010	0.0%	244.6
enhancement_clahe_resnet18	0.9954	0.9954	0.7356	0.0%	16.7
enhancement_denoise_resnet18	0.9954	0.9954	0.7012	0.0%	7.9
mediapipe_crop_vit	0.9851	0.9707	0.0000	17.15%	11.2
mediapipe_landmarks_rf	0.9741	0.9552	0.0000	17.15%	16.6
mediapipe_landmarks_svm	0.9706	0.9723	0.0000	17.15%	19.8
mediapipe_landmarks_mlp	0.9705	0.9556	0.0000	17.15%	35.0
mediapipe_crop_resnet18	0.8859	0.8627	0.0000	17.15%	18.9

Mọi pipeline dùng MediaPipe đều sập về 0% ở corruption khó nhất — kể cả pipeline có Clean Acc cao.

6.1 So sánh Accuracy giữa các pipeline




6.2 Trade-off Latency / FPS




Landmark-based (MLP/SVM/RF) và ResNet18 trên ảnh thô có FPS cao nhất, phù hợp ứng dụng thời gian thực.

6.3 Robustness dưới Corruption




6.4 Qualitative — Module Representation

Representation Module — cùng input, các phép biến đổi khác nhau



6.5 Qualitative — Module Recognizer (toàn bộ 13 pipeline)


Recognizer Module — cùng input, kết quả của từng pipeline hoàn chỉnh



Overlay xanh = đúng, đỏ = sai. Mọi pipeline dùng MediaPipe đều đỏ giống nhau ở đúng 3 ảnh tối đó — lỗi lan truyền từ representation chung.

6.6 Case Study — "Accuracy cao mà vẫn sập"

So sánh 3 pipeline trên ảnh: A909.jpg



mediapipe_crop_vit: Clean Acc = 98.5%

Nhưng accuracy thực (tính cả Unknown):

$$\frac{2110}{2600} = \mathbf{81.15\%}$$

Thấp hơn 17 điểm % so với số "đẹp"


ban đầu — vì 17.15% ảnh bị MediaPipe bỏ sót tay không được tính vào accuracy chuẩn.

raw_resnet18 (không qua bước detect) vẫn nhận đúng "A" 100% trên đúng ảnh này.

6.7 Diễn giải nội bộ CNN — Grad-CAM


raw_resnet18

raw_resnet18 - ảnh trong folder18 - 1979.jpg (output featuremap ở 276, model 118)



mediapipe_crop_resnet18


mediapipe_crop_resnet18 - ảnh trong folder18 - 2111.jpg (output featuremap ở 118, model 145)



Activation map co dần qua conv1→layer4 (224→7), kênh tăng 64→512. Grad-CAM khoanh đúng vùng bàn tay quyết định nhãn dự đoán.

6.8 Không gian đặc trưng — UMAP / t-SNE theo lớp


Landmark Feature Space (42-d) — colored by class



Vector landmark 42-d, lấy mẫu 30 ảnh/lớp trên `test_split`. 26 lớp A–Z tách cụm rõ ràng — landmark là đặc trưng phân biệt tốt cho MLP/SVM/RF.

6.9 Không gian đặc trưng — Representation có làm lệch không?

Same images, different representations — colored by representation
(same ResNet18 backbone weights throughout)



Cùng ảnh, 4 representation khác nhau, cùng backbone ResNet18. CLAHE/Gamma/Raw nằm rất gần nhau (cùng cụm nhỏ) — enhancement nhẹ không đổi nhiều không gian đặc trưng. MediaPipe Crop (cam) tách hẳn vị trí khác — đổi representation mới thực sự dịch chuyển không gian đặc trưng.

7. Kết luận

Đánh giá đúng metric

Clean accuracy "chuẩn" có thể che giấu thất bại thực — phải dùng accuracy tính cả Unknown.

Lỗi 2 tầng nguy hiểm hơn lỗi 1 tầng

Thêm bước detect tay (MediaPipe) thêm 1 điểm gãy — robustness sập về 0% dù backbone mạnh.

Đơn giản có thể bền hơn

raw/enhancement + ResNet18/ViT không bao giờ sập dưới 70% ở corruption xấu nhất.

Limitations

Một số representation chưa hoàn thiện (YOLO-crop, segmentation-mask, fusion là stub); chỉ 1 dataset (ASL Alphabet, ảnh studio).

Future Work

Hoàn thiện YOLO-crop/segmentation/fusion; đánh giá trên dữ liệu webcam thực tế ngoài studio; thử fallback raw khi MediaPipe gãy.

Thành viên	Nhiệm vụ
Trần Quang Hưng - 20235502	YOLOv8 pipeline, chuẩn bị dataset, hand detection
Đỗ Đăng Vũ - 20235578	Classifier (ResNet/MobileNet) & transforms, đánh giá robustness, visualization
Lê Hoàng Tùng - 20235572	Demo (OpenCV/Gradio), evaluation pipeline, báo cáo

THÔNG TIN LIÊN HỆ

Nhóm: Computer Vision Capstone — HUST

► **Github:** <https://github.com/>

Xin chân thành cảm ơn Hội đồng đã lắng nghe!

- [1] C. Lugaresi et al., “MediaPipe: A Framework for Building Perception Pipelines,” arXiv:1906.08172, 2019.
- [2] K. He, X. Zhang, S. Ren, J. Sun, “Deep Residual Learning for Image Recognition,” CVPR, 2016.
- [3] X. Zhai et al., “Sigmoid Loss for Language Image Pre-Training (SigLIP),” ICCV, 2023.
- [4] Kaggle, “ASL Alphabet Dataset,” <https://www.kaggle.com/datasets/grassknoted/asl-alphabet>.
- [5] L. McInnes, J. Healy, J. Melville, “UMAP: Uniform Manifold Approximation and Projection,” arXiv:1802.03426, 2018.
- [6] L. van der Maaten, G. Hinton, “Visualizing Data using t-SNE,” JMLR, 2008.

- [7] R. Selvaraju et al., “Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization,” ICCV, 2017.

A decorative graphic on the left side of the slide. It features a dark blue background with a large, stylized circular pattern composed of many small red dots. The dots are arranged in concentric, slightly offset rings, creating a sense of depth and movement. The word "HUST" is centered within this pattern.

HUST

THANK YOU !

